

MÁSTER EN TRATAMIENTO ESTADÍSTICO-COMPUTACIONAL DE
LA INFORMACIÓN

TRABAJO FIN DE MÁSTER
CURSO 2025/26

Clasificación celular en imágenes de inmunofluorescencia múltiple de cáncer pulmonar de célula pequeña.

Eloy de la Infanta Clavé



UNIVERSIDAD COMPLUTENSE DE MADRID

FACULTAD DE CIENCIAS MATEMÁTICAS

&

UNIVERSIDAD POLITÉCNICA DE MADRID

ESCUELA TÉCNICA SUPERIOR DE INGENIEROS DE TELECOMUNICACIÓN

Institución: Centro Nacional de Investigaciones Oncológicas (CNIO)

Tutores: Isabel Peset Martín, Jose María Gracia Rodríguez, Joan Salvador
Russo Cabrera

Ponente: Carlos Gregorio Rodríguez

Madrid, Julio 2026

Resumen

Introducción: El análisis de imágenes de inmunofluorescencia múltiple (mIF) genera datos de alta dimensionalidad que son fundamentales para la caracterización de microambientes complejos, como el del cáncer de pulmón de célula pequeña (SCLC). El gran volumen de datos y su complejidad imposibilita el etiquetado manual, y la ausencia de etiquetas de referencia (*ground truth*) dan lugar a un problema de clasificación no supervisado que, hasta la fecha, no tiene un algoritmo que lo resuelva de forma satisfactoria. Este trabajo aborda el diseño y la implementación de un algoritmo robusto, escalable y automatizado para el fenotipado celular en imágenes de mIF.

Materiales y Método: Imágenes de inmunofluorescencia múltiple (mIF) con 16 canales fueron segmentadas a nivel celular. Posteriormente, a partir del algoritmo de fenotipado de scimap 2.3.5, se desarrolló un algoritmo para la clasificación automática de células a través del etiquetado secuencial por regiones subcelulares, con umbrales basados en modelos de mezclas gaussianas (GMM). Además se diseñó un algoritmo de reetiquetado para regiones no clasificadas.

Resultados y Conclusiones: Se ha diseñado un flujo de trabajo capaz de clasificar automáticamente poblaciones celulares a partir de datos segmentados. Este sistema gestiona el volumen y complejidad de imágenes de mIF y elimina el cuello de botella del etiquetado manual. Estos resultados establecen la base de datos necesaria para realizar análisis espaciales posteriores, permitiendo profundizar en la arquitectura inmunológica del CPCP.

Abstract

Introduction: The analysis of multiplexed immunofluorescence (mIF) images generates high-dimensional data that are fundamental for the characterization of complex microenvironments, such as that of small cell lung cancer (SCLC). The large volume and complexity of the data make manual labeling unfeasible, and the absence of reference labels (*ground truth*) gives rise to an unsupervised classification problem for which, to date, no algorithm provides a satisfactory solution. This work addresses the design and implementation of a robust, scalable, and automated algorithm for cellular phenotyping in mIF images.

Materials and Methods: 16-channel multiplexed immunofluorescence (mIF) images were segmented at the cellular level. Subsequently, based on the scimap 2.3.5 phenotyping algorithm, an algorithm was developed for automated cellular phenotyping via sequential labeling by subcellular regions, utilizing thresholds based on Gaussian Mixture Models (GMM). In addition, a relabeling algorithm was designed for unclassified regions.

Results and Conclusions: A workflow capable of automatically classifying cellular populations from segmented data has been designed. This system manages the volume and complexity of mIF images and eliminates the manual labeling bottleneck. These results establish the dataset necessary to perform subsequent spatial analyses, enabling a deeper insight into the immunological architecture of SCLC.

Índice

1. Introducción	4
2. Herramientas y datos	9
2.1. Inmunofluorescencia múltiple - MACSima	9
2.2. SpatialData	9
2.3. Algoritmos de segmentación: Cellpose	10
2.4. <i>Ground truth</i> y métodos de evaluación	11
3. Desarrollo del algoritmo de fenotipado	14
3.1. Scimap	14
3.1.1. El algoritmo de fenotipado de scimap	14
3.1.2. Resultados	17
3.2. Clustering Jerárquico Supervisado	19
3.2.1. Modificación del cálculo de umbrales por GMM	20
3.2.2. Fenotipado jerárquico	20
3.2.3. Clustering de Leiden	21
3.2.4. Tratamiento de las células <i>Undefined</i>	24
3.2.5. Resumen e inconvenientes	24
3.2.6. Resultados y evaluación	25
3.3. Fenotipado jerárquico con GMM según BIC	26
3.3.1. Elección del número de componentes por BIC y D de Ashman	26
3.3.2. Resultados e inconvenientes	28
3.4. Fenotipado a través de regiones subcelulares	29
3.4.1. Recorte de máscaras celulares	29
3.4.2. Fenotipado a través de regiones subcelulares	31
3.4.3. Resultados e inconvenientes	34
4. Resultados	37
5. Conclusión	40

1. Introducción

El cáncer de pulmón es uno de los mayores desafíos para la salud pública a nivel mundial. Es el cáncer con mayor incidencia, según los datos de GLOBOCAN 2022 [3], publicados por la Agencia Internacional para la Investigación del Cáncer (IARC). Su impacto se ve amplificado por su difícil detección temprana y su agresividad.

Como patología, el cáncer de pulmón no se considera un único ente, sino que se subdivide en diferentes variantes según su histología [15]. Fundamentalmente se consideran dos subtipos: el cáncer de pulmón de célula pequeña (CPCP o SCLC por sus siglas en inglés) y el cáncer de pulmón de célula no pequeña (CPCNP o NSCLC por sus siglas en inglés). A su vez estos distintos subtipos determinan múltiples líneas de tratamiento.

Aunque el SCLC represente solamente un 15 % de los casos de cáncer de pulmón, presenta una mortalidad muy alta, debido principalmente a dos motivos [11]. El primero, y a diferencia del NSCLC, a la hora de ser diagnosticados los pacientes con SCLC ya presentan metástasis en un 70 % de los casos, i.e., diseminación a otros órganos. El segundo es que la tasa de supervivencia a 5 años después del diagnóstico es de apenas un 7 % .

Las líneas de tratamiento en SCLC son escasas, siendo la quimioterapia la única opción de tratamiento durante décadas, que si bien suele responder de forma positiva inicialmente, tiene una recaída casi sistemática. Posteriormente, se aprobó el uso de inhibidores del punto de control inmunitario (ICI), en concreto el eje PD-1/PD-L1 en combinación a quimioterapia, demostrando una mejora modesta en la supervivencia de un porcentaje limitado de pacientes. Actualmente, la búsqueda de nuevas terapias y la estratificación de pacientes en predicción a respuesta a tratamientos son áreas muy activas en la investigación del SCLC.

Algunas de las particularidades de este tipo de tumor radican en su heterogeneidad [10] y su plasticidad [5]. A nivel molecular, el SCLC se define por la pérdida bialélica casi universal de los supresores tumorales *TP53* y *RB1*. Sin embargo, han sido análisis transcriptómicos recientes los que han detectado una gran heterogeneidad, definiendo distintos subtipos moleculares impulsados por factores de transcripción maestros (TFs): SCLC-A (ASCL1) y SCLC-N (NEUROD1), con características neuroendocrinas; SCLC-P (POU2F3) y SCLC-TN (triple negativo), considerados menos neuroendocrinos. Adicionalmente, las células tumorales de SCLC presentan una plasticidad celular inherente que les permite una transición lineal desde estadios más neuroendocrinos a menos neuroendocrinos. Son ambas características las que confieren a tumores SCLC resistencia a tratamientos con quimioterapia.

Anteriormente, se consideraba que el SCLC era un tumor inmunológicamente frío o *immune cold*, i.e., con poca infiltración del sistema inmunitario, y que por tanto pasa desapercibido a la respuesta inmunitaria contra el tumor. Sin embargo, recientemente [6] se ha visto que algunos subtipos de SCLC no son *immune cold*, sino que existe una respuesta inmune, que lo convierte en un tumor inmunológicamente *caliente*, habiendo dos tipos de inflamación [7]. Por un lado, una inflamación no productiva o protumoral, que se caracteriza por un infiltrado inmune principalmente mieloide supresor y que, a pesar de presentar una respuesta inmune previa no se beneficia de tratamiento con ICI. Por otro lado, una inflamación productiva o antitumoral, en la que el componente inmune

infiltrante principal son linfocitos T, y que resulta en una mejora en la respuesta contra el tumor ante un tratamiento con ICI. En aquellos casos que el tumor es *immune cold*, tratamientos combinando quimioterapia e ICI no aportan mejora sobre quimioterapia en monoterapia.

Todo este conocimiento se ha extraído con tecnologías no espaciales y consideradas de *bulk*, por lo que la información extraída es muy limitada. A consecuencia de esto, se pierde la arquitectura del tejido, la distribución a nivel célula única del tumor, el estroma y componentes del sistema inmune.

Para mejorar el conocimiento del SCLC y la capacidad de diagnóstico, se requiere de un entendimiento más profundo del microambiente tumoral, que se ha visto limitado por la escasez de muestras. En el SCLC, al ser detectado en un estado muy avanzado, operar a estos pacientes no supone un beneficio clínico, con la consecuente ausencia de muestras. De este modo, el análisis de ómicas espaciales y a nivel de célula única de biopsias no solo permite entender la biología del SCLC, sino que también puede repercutir desde el diseño de nuevas líneas de tratamiento explotando las vulnerabilidades del tumor y su entorno como en el descubrimiento de marcadores de respuesta a las terapias actuales.


Las microscopía de inmunofluorescencia múltiple (mIF) es una técnica novedosa que parte del principio de la inmunohistoquímica (IHQ). La IHQ es una técnica para detectar y localizar proteínas específicas en una muestra de tejido. Para ello, se utilizan anticuerpos. Un anticuerpo es una inmunoglobulina que se une específicamente a la proteína que se pretende detectar, la cual se denomina *antígeno*. El anticuerpo lleva acoplada una enzima (peroxidasa o fosfatasa) la cual, al añadir posteriormente un sustrato, produce un cambio de color. Al observar estas imágenes bajo un microscopio se puede detectar la presencia de la proteína o marcador en la muestra y su ubicación espacial a través del color producido.

La IHQ es el patrón estándar para el diagnóstico en el ámbito clínico y de investigación, por ser una técnica fiable y económica, pero generalmente solo permite la búsqueda de una o dos proteínas simultáneas por corte de tejido. Si se pretendiese utilizar un panel de varios marcadores distintos se requerirían muchos cortes del tejido, lo que consumiría muestras valiosas, además de impedir estudiar la disposición e interacción entre esos marcadores ya que con cada corte histológico se observa un plano diferente de la muestra tridimensional.


La mIF permite solventar este problema. Los anticuerpos, en lugar de una enzima, tienen unido un fluorocromo, que emite luz en una longitud de onda concreta al ser iluminado con un haz de luz de una longitud de onda adecuada. Al elegir varios fluoróforos con longitudes de onda distintas, se puede detectar la presencia de varias proteínas sobre una misma imagen. Sin embargo, esta estrategia permitiría la detección de un máximo de 6-10 marcadores al mismo tiempo, ya que con un número mayor de ellas las señales comenzarían a mezclarse.

Para permitir un panel con un mayor número de marcadores la plataforma MACSima, con la que se han generado las imágenes utilizadas en este trabajo, utiliza ciclos iterativos. Se tiñe el tejido con 3 marcadores, se toma la imagen digital del tejido, se borra, ya sea eliminando los fluorocromos químicamente o con un quemado lumínico, se toma otra

imagen para estimar la fluorescencia de fondo y se repite. Finalmente se descompone cada imagen en tantos canales como marcadores se hayan utilizado, se alinean y se elimina la fluorescencia de fondo restando las intensidades obtenidas tras el borrado. En la 1 se ven imágenes de ejemplo de IHQ y mIF.



(a) Imagen de ejemplo de IHQ



(b) Imagen de ejemplo de mIF

Figura 1: Ejemplos de imágenes de IHQ y de mIF

Nótese que, aunque la imagen obtenida sea bidimensional, la realidad del tumor es tridimensional, y particularmente en el caso del SCLC, hay que tener en cuenta que, aunque el corte del tejido sea fino, es posible tener células superpuestas, lo cual dificulta sustancialmente la segmentación celular de las imágenes, además de poder suponer un problema para los análisis espaciales posteriores.

El resultado directo es una imagen con gran cantidad de canales, cuyas intensidades representan la presencia de proteínas específicas. La estructura es típicamente un tensor de dimensiones (x, y, c) , siendo (x, y) las coordenadas espaciales que definen los píxeles de la imagen, y c los distintos biomarcadores medidos. Al determinar una intensidad a nivel de célula para cada marcador se obtiene una matriz $X \in \mathbb{R}^{n \times c}$, siendo n el número de células detectadas en la imagen. En la figura 3 se ven algunos de los canales de la imagen que se usará como ejemplo a lo largo de todo el trabajo.

Esta estructura de datos es el punto de partida para aplicar cualquier análisis. Permite utilizar algoritmos de computer vision para segmentar las células, extraer matrices de expresión a nivel celular y muy especialmente identificar características fundamentales de las células detectadas, como el fenotipo (i.e., el tipo de célula, como tumorales, endoteliales o inmunes) o estado de activación. Sin embargo, para fenotipar las células no basta con la imagen o las intensidades medias de los marcadores por célula. Se requiere de un conocimiento previo que determine qué fenotipos celulares se pretende identificar y qué proteínas deben expresar dichos fenotipos. Esa información vendrá dada por una tabla de fenotipado. El fenotipado, i.e., la clasificación de células individuales según su perfil de expresión de proteínas, es a día de hoy el principal cuello de botella en el análisis de

imágenes de mIF. Posteriormente, se puede aplicar estadística espacial o teoría de grafos para modelar las interacciones de las diferentes poblaciones celulares.

Estas tecnologías producen grandes volúmenes de datos complejos. Actualmente uno de los desafíos más significativos es el procesamiento y análisis de estas imágenes de alta dimensionalidad, que exige el desarrollo de algoritmos robustos y automatizados para la detección celular y fenotipado, ya que la dimensión de los datos supera por mucho las limitaciones del análisis manual.

El objetivo de este trabajo es desarrollar un algoritmo de fenotipado en imágenes de mIF, específicamente de Cáncer de Pulmón de Célula Pequeña, aunque aplicable a otras histologías, que lidie correctamente con los inconvenientes de esta tecnología todavía en desarrollo: tinción inespecífica, diferencias de escala para un mismo marcador en diferentes imágenes y los problemas derivados de la segmentación celular.

A lo largo de este trabajo se muestran los algoritmos que se han ido construyendo sucesivamente con el fin de solucionar los respectivos problemas de los algoritmos anteriores. Como base para el desarrollo se ha usado el algoritmo de la librería `scimap` [8], que si bien fue ideado para recibir unos umbrales predefinidos por el usuario, incluye también un algoritmo no supervisado para calcularlos en el caso de que no vengan predefinidos.

A partir de ese algoritmo se desarrollan estrategias más precisas y robustas de umbralizado, con umbrales calculados de forma jerárquica y basada en modelos de GMM, con criterios de selección del número de componentes en base a criterios de información y de separación de la clase positiva. Para incluir la colocación espacial de marcadores a nivel intracelular se incluye una segmentación en regiones subcelulares y un fenotipado de subregiones celulares.

En este proyecto se utilizaron imágenes obtenidas con la plataforma MACSima (Miltényi), de un panel de 16 anticuerpos (ver tabla 2) en muestras tumorales de pacientes con SCLC que participaron en el ensayo clínico 2SMALL. Con el fin de evaluar el desempeño de los diferentes algoritmos desarrollados, los resultados se compararon contra un fenotipado reducido manual realizado sobre algunas de las imágenes de mIF.

Marker	Target Population	Status	Expected pattern	Observed pattern
DAPI	DNA	Optimal	Intranuclear	Intranuclear
CD3	T cells	Optimal	Membranous	Membranous
CD4	Helper T cells	Optimal	Membranous	Membranous
CD8a	Cytotoxic T cells	Optimal	Membranous	Membranous
FoxP3	Regulatory T cells	Optimal	Intranuclear	Intranuclear
CD11b	Monocytes	Optimal	Membranous	Membranous
CD68	Macrophages	Optimal	Membranous	Membranous
CD163	M2 Subset of Macropages	Optimal	Membranous	Membranous
HLA-DR	Antigen Presenting Cells	Optimal	Membranous	Membranous
CD16	Phagocytic Immune Cells	Not Optimal	Membranous	Membranous
Pan-Cytokeratin	Tumour Cells	Optimal	Cytoplasmatic	Cytoplasmatic - Diffuse
Chromogranin A	NE Tumour Cells	Optimal	Intracellular - granular	Intracellular - granular
Synaptophysin	NE Tumour Cells	Optimal	Cytoplasmatic - Diffuse	Cytoplasmatic - Diffuse
INSM1	NE Tumour Cells	Optimal	Intranuclear	Membranous
SMA	Fibroblasts	Optimal	Membranous	Membranous
CD31	Endothelial Cells	Optimal	Membranous	Membranous
Ki67	Proliferative Cells	Optimal	Intranuclear	Intranuclear

Figura 2: Tabla con el panel de 16 anticuerpos, sus poblaciones objetivo y sus regiones de marcaje

Este trabajo se ha desarrollado en colaboración con la Unidad de Microscopía Confocal y la Unidad de Investigación Clínica de Cáncer Pulmón H12O-CNIO, ambos pertenecientes al Centro Nacional de Investigaciones Oncológicas (CNIO). Su ayuda, además de facilitar el acceso a muestras del ensayo clínico 2SMALL, ha sido fundamental como fuente de conocimiento experto en los ámbitos de biología, oncología y microscopía, así como para validar las herramientas desarrolladas y los resultados obtenidos.

El resto de la memoria detalla el proceso seguido en desarrollo del algoritmo. En la Sección 2 se detalla la información sobre las imágenes de inmunofluorescencia múltiple, el uso de `SpatialData 0.6.1` y la segmentación celular mediante `cellpose 4.0.9`, introduciendo además el *ground truth* y los métodos que servirán para la evaluación. En la Sección 3 se recorren sucesivamente los algoritmos que se han ido construyendo, desde el algoritmo base de `scimap 2.3.5` hasta el algoritmo final. En la Sección 4 se recoge el desempeño global del algoritmo desarrollado, y en la Sección 5 se sintetizan las principales conclusiones de la investigación y se muestran algunas posibles líneas a futuro.

2. Herramientas y datos

2.1. Inmunofluorescencia múltiple - MACSima

Imágenes de mIF obtenidas con la plataforma MACSima (Miltenyi) se usarán para la identificación de componentes del sistema inmune, estroma, tumor, y su disposición espacial. Estas imágenes son sustancialmente más informativas que las obtenidas por inmunoquímica, lo que permite distinguir las poblaciones comunes de forma más precisa, e identificar poblaciones minoritarias que de otra manera serían indistinguibles. Sin embargo, el volumen de datos obtenidos imposibilita el fenotipado manual, requiriendo de métodos automatizados con toma de decisiones basados en modelos estadísticos.




Figura 3: Canales DAPI, Ki 67 y CD4 de la imagen de mIF.

Es importante remarcar la necesidad de un algoritmo de fenotipado automático para este tipo de imágenes. Una sola región de interés dentro de una muestra supera fácilmente las 15,000 células, y una imagen completa puede superar el millón de células individuales, imposibilitando una revisión manual.

Para técnicas como la IHQ y la citometría de flujo, la estrategia de fenotipado automático habitual es un umbralizado estricto con un umbral prefijado para todas las muestras. Esto no es aplicable a imágenes de mIF, dado que la técnica genera niveles de intensidad muy variables incluso dentro de la misma imagen. Esta es la razón fundamental por la que es necesario explorar algoritmos de fenotipado que se ajusten a los datos de cada región de interés.

Con las imágenes segmentadas a nivel celular y tras haber fenotipado cada célula individualmente, el siguiente paso sería realizar un análisis de las relaciones espaciales entre los distintos tipos celulares, con el objetivo de hallar relaciones entre los resultados obtenidos de las imágenes y la respuesta de los pacientes a distintos tipos de tratamiento. De esta manera se puede obtener información como el estado proliferativo del tumor y la infiltración inmune, entre otras muchas métricas. En este trabajo no se ha llegado a desarrollar esta etapa.

2.2. SpatialData

El tamaño de las imágenes, junto con el número de canales, obliga a trabajar de forma particular con estas imágenes, que pueden llegar a varios gigabytes de almacenamiento.

Como operar con la totalidad de la imagen requeriría demasiada memoria, se usan estructuras alternativas, como las imágenes multiescala, que permiten guardar la imagen como parches más pequeños superpuestos en los bordes. Esto permite solucionar algunos de los problemas a nivel computacional. Por otro lado, hay que guardar y gestionar la información de las formas de las células, o anotaciones particulares, como el tipo de cada célula de la imagen.

Para gestionar los dos problemas anteriores sirve la librería de Python **SpatialData** 0.6.1 [4], que se usa en muchos entornos de imagen médica. Trabaja con objetos formados por imágenes (Images), etiquetas (Labels), puntos (Points), formas (Shapes) y tablas (Tables), que se guardan en formato **.zarr**. Sopa gestiona las imágenes multiescala, y permite visualizaciones, anotaciones, cambios de sistema de coordenadas y transformaciones.

2.3. Algoritmos de segmentación: Cellpose

Para la segmentación de las imágenes de inmunofluorescencia múltiple se utiliza Cellpose [12], a través de la librería sopa [2]. Sopa es una librería que incluye varias herramientas para el ámbito de las ómicas espaciales. Incluye herramientas para la segmentación celular, de agregación de intensidades por células y de análisis espacial de los datos obtenidos.




Figura 4: Etapas del pipeline completo de sopa [2]

Para la segmentación de las imágenes a nivel celular se opta por el modelo *cpsam* [9], una versión reentrenada del *Segment Anything Model* (SAM) de Meta. SAM utiliza un codificador de imágenes profundo y un decodificador ultraligero para generar las máscaras de segmentación, lo cual da mejores resultados, pero es computacionalmente muy costoso. Salvo algunos inconvenientes intrínsecos del tipo de imágenes, que al presentar células superpuestas parcial o totalmente, dificultan la segmentación, los resultados son

satisfactorios, y no se ha modificado esta etapa del tratamiento de datos.

En las figuras 5a y 5b se ven respectivamente los resultados de la segmentación con un modelo ligero (*nuclei*) y con *cpsam* usando únicamente el canal DAPI y añadiendo una expansión artificial uniforme alrededor del núcleo.




Figura 5: Comparación de las segmentaciones con los modelos *nuclei* y *cpsam*

2.4. *Ground truth* y métodos de evaluación

Se dispone de un fenotipado semi-manual proporcionado por Unidad de Investigación Clínica de Cáncer de Pulmón H12O-CNIO. Debido a la cantidad de células y de canales, este fenotipado se ha realizado sobre un número reducido de células e incluyendo menos fenotipos de los que se pretenden detectar. Sin embargo, se utilizará como *ground truth* con el fin de evaluar los distintos algoritmos.

Para la obtención de este *ground truth* se ha usado QuPath 0.6.0, que incluye una herramienta que permite, a partir de unas pocas células etiquetadas, emplear unas ciertas variables para entrenar un Random Forest, y utilizar las predicciones como etiquetas. A partir de las etiquetas predichas, se corrigen los errores, que se añaden a los datos de entrenamiento de los sucesivos Random Forest siguientes. Se repite este ciclo de predicción y corrección con intervención humana hasta llegar a un resultado satisfactorio. En la figura 6 se ven las células coloreadas según el *ground truth*, y en la figura 7 se ven las intensidades medias de los distintos canales en cada clase del *ground truth*.




Figura 6: Células de la imagen coloreadas según el *ground truth*.




Figura 7: Intensidades medias de los distintos canales en cada clase del *ground truth*.

Para evaluar la clasificación obtenida por cada uno de los sucesivos algoritmos se realiza en primer lugar un análisis visual, y en segundo lugar una comparación con el *ground truth*. El análisis visual permite detectar no solo la calidad de la clasificación, sino el tipo de errores y su posible causa, lo cual es mucho más útil para realizar correcciones

que la comparación con el *ground truth* a través de tablas de contingencia y métricas de clasificación, aunque no se obtenga un resultado numérico.

3. Desarrollo del algoritmo de fenotipado

A lo largo del trabajo se ha ido desarrollando el algoritmo de fenotipado a través de sucesivas versiones, que han ido encontrando distintos errores en base a las particularidades de los datos. En esta sección se explican las sucesivas modificaciones que se han introducido en el algoritmo de fenotipado.

3.1. Scimap

Scimap [8] es un proyecto de análisis de datos espaciales a nivel molecular. Está disponible como librería de Python, e incluye, entre otras funciones, una herramienta sencilla para el fenotipado celular a partir de matrices de intensidad media por canales.

La librería de scimap incluye, además del algoritmo de fenotipado, herramientas de análisis espacial, visualización, reducción de dimensionalidad y preprocesado. Particularmente es interesante el análisis espacial, que permite extraer conclusiones biológicas (como el nivel de infiltración de células inmunes en el tumor) una vez que se tenga un fenotipado definitivo.

3.1.1. El algoritmo de fenotipado de scimap

En el algoritmo de fenotipado de scimap el conocimiento previo se resume a una tabla de fenotipado. Esto es una tabla que tiene por filas a cada tipo celular que se pretende encontrar y por columnas a cada marcador que se utiliza para el fenotipado. En cada casilla se indica si el marcador debe ser positivo, negativo o no es relevante para el fenotipo correspondiente. Se pueden definir sucesivamente los fenotipos, desde linajes amplios a subtipos celulares muy concretos, con una estructura de árbol de decisión. De esta manera se concatenan las condiciones necesarias para llegar a un cierto nodo. En la figura 8 se ve un ejemplo de tabla de fenotipado.

Entry Node	Exit Node	CD8a	CD68	Ki_67	CD163	CD3	FoxP3	HLA_DR	CD4	CD11b	Pan_Cytokeratin	Actin	CD31
All	Tumour			anypos		allneg			allneg			anypos	
All	Lymphoid					pos						neg	
All	Myeloid		anypos			neg				anypos		neg	
All	Stroma					neg						neg	anypos anypos
Lymphoid	CD8_T_cell	pos											
Lymphoid	CD4_T_cell								pos				
Lymphoid	Treg						pos		pos				
Myeloid	Monocyte									pos			
Myeloid	Macrophage		pos										
Stroma	Endothelial												pos
Stroma	Fibroblast											pos	
Tumour	Proliferative_Tumour			anypos									
Tumour	Non_Proliferative_Tumour			anyneg									
Macrophage	M1_Macrophage							pos					
Macrophage	M2_Macrophage				pos								

Figura 8: Ejemplo de tabla de fenotipado

En este caso, para que una célula fuese etiquetada como *CD8_T_cell* se tendrían que cumplir tanto las condiciones necesarias para pasar de *All* a *Lymphoid*, que son ser positiva en CD3 y negativa en Pan_Cytokeratin como las necesarias para pasar de *Lymphoid*

a *CD8₋T₋cell*, que es ser positiva en CD8a.

El algoritmo de fenotipado de scimap se basa en dos funciones, `scimap.rescale` y `scimap.phenotype_cells`. La primera se encarga de generar umbrales de positividad y reescalar las variables, y la segunda se encarga de calcular las puntuaciones de cada fenotipo para cada célula y determinar su fenotipo final en base a esas mismas puntuaciones. A continuación se explica en detalle el algoritmo de scimap [8], incluyendo algunas modificaciones realizadas a lo largo de este trabajo.

En principio y asumiendo que la tabla de fenotipado viene definida, el problema se reduce a definir qué células son positivas para cada marcador. Dada la matriz de intensidades medias, el algoritmo de scimap considera, para cada canal de la imagen (i.e., cada columna de la matriz de intensidades medias) una distribución de probabilidad conjunta, de una variable continua, de la que se considera que la columna es una muestra, y ajusta un *Gaussian Mixture Model (GMM)* con lo que aproxima la distribución de las intensidades medias como la suma de k (por defecto, $k = 3$) variables aleatorias normales.

Asigna a la componente de mayor media la clase positiva, y al resto de componentes la clase negativa. Fija el umbral en el punto medio entre la media de la penúltima componente (la mayor de la clase negativa) y la última (la componente de la clase positiva). Reescala las variables de forma lineal a trozos para que el umbral de clasificación sea 0,5, y los datos estén en $[0, 1]$. Si la intensidad de una célula es mayor que el umbral, es positiva para ese marcador, y si es menor es negativa.

Se genera una puntuación para cada fenotipo en función de los valores reescalados de cada uno de los canales, y se le otorga el fenotipo que tenga mayor puntuación.

Para calcular esta puntuación a partir de las intensidades reescaladas, scimap evalúa las reglas de la tabla de fenotipado, que pueden ser de 6 tipos: **pos**, **neg**, **anypos**, **anyneg**, **allpos** o **allneg**. De forma intuitiva, **pos** y **neg** son las formas genéricas de indicar que un marcador debe ser positivo o negativo respectivamente para un fenotipo concreto, **anypos** y **anyneg** solo exigen que se dé positividad o negatividad en alguno de los marcadores indicados, y **allpos** y **allneg** son estrictos, es decir, todos los marcadores indicados con **allpos** deben ser positivos para ese fenotipo.

A cada regla le otorga una puntuación, y a partir de esas puntuaciones de reglas genera una puntuación para el fenotipo. Si denotamos como x al vector de intensidades reescaladas (cuyos valores están acotados en el intervalo $[0, 1]$), las subpuntuaciones se calculan de la siguiente manera:

- **pos** : La puntuación es la media aritmética de las intensidades de los marcadores que tengan **pos** en la fila del fenotipo que evaluamos.

$$p_{pos} = \frac{1}{|pos|} \sum_{i \in pos} x_i$$

Siendo pos el conjunto de los marcadores marcados con **pos** en la fila correspondiente. Si un marcador **pos** está por debajo del umbral, se indica a través de la variable

pos_fail. Si más de un marcador **pos** está por debajo del umbral, la puntuación pasa a ser 0.

- **neg** : La puntuación es la media de 1 menos la intensidad para los marcadores **neg**.

$$p_{neg} = \frac{1}{|neg|} \sum_{i \in neg} (1 - x_i)$$

Siendo *neg* el conjunto de los marcadores marcados con **neg** en la fila correspondiente. Análogamente, si un marcador **neg** está por debajo del umbral, se indica a través de la variable **neg_fail**. Si más de un marcador **neg** está por debajo del umbral, la puntuación pasa a ser 0.

- **anypos** : La puntuación es el máximo de los marcadores **anypos**.

$$p_{anypos} = \max_{i \in anypos} x_i$$

- **anyneg** : La puntuación es el máximo de los marcadores invertidos.

$$p_{anyneg} = \max_{i \in anyneg} (1 - x_i)$$

- **allpos** : Se toma inicialmente el máximo de las intensidades, pero si alguno de los marcadores no supera el umbral, que al reescalar es 0,5, la puntuación se reemplaza por 0. Si todos los marcadores superan el umbral, se suma 0,01 a la puntuación para otorgar una ventaja competitiva.
- **allneg** : Se toma el máximo de las intensidades invertidas con la misma restricción estricta respecto al umbral, añadiendo también la constante de 0,01 si supera esa restricción.

Una vez calculadas las puntuaciones para las categorías (**pos**, **neg**, ...) no vacías en la definición del fenotipo, se obtiene una puntuación base total mediante el promedio de las mismas:

$$\text{Puntuación Total} = \frac{p_{pos} + p_{neg} + p_{anypos} + p_{anyneg} + p_{allpos} + S_{allneg}}{N_{cat}}$$

Donde N_{cat} es el número de restricciones distintas que el fenotipo exige evaluar, y tomando las puntuaciones de aquellas categorías que no se hayan evaluado por no estar presentes en la fila del fenotipo en la tabla por 0.

Finalmente, el algoritmo penaliza el fallo de restricciones **pos** y **neg**. Tras determinar el fenotipo candidato por máxima puntuación, el sistema revisa estos fallos: si la célula fue asignada a un fenotipo en el que incumplió alguna restricción **pos** o **neg**, es reclasificada de forma definitiva como **Undefined**.

Originalmente el algoritmo incluía un tratamiento distinto de estos casos. Si un solo marcador **pos** o **neg** fallaba, mantenía el fenotipo, pero precedido de un *likely*-. Esto era un problema para reetiquetar esas células más adelante.

Si la tabla de fenotipado tiene varios niveles de fenotipado, como es el caso de la tabla de la figura 8, este proceso se repite sucesivamente hasta haber recorrido todo el árbol. Nótese que, al haberse realizado ya el reescalado para todas las variables, en cada etapa basta generar las puntuaciones para los fenotipos que correspondan y etiquetar cada célula como el fenotipo de mayor puntuación. No se recalculan umbrales de ninguna manera, sino que se usan los obtenidos sobre la población total al aplicar `rescale`.

Esto resuelve de forma sencilla el problema del etiquetado, pero la obtención de umbrales es poco robusta, y no tiene una significación estadística. Por otro lado, suele haber algunas células que no encajan en ninguno de los fenotipos. En esos casos, scimap las deja etiquetadas como *Undefined*. Es necesario implementar un tratamiento de células indefinidas y no está desarrollado en scimap. Sin embargo, el algoritmo de fenotipado de scimap es un algoritmo sencillo que sirve como *benchmark* y como base para otros algoritmos.

3.1.2. Resultados




Figura 9: Resultado de scimap con la tabla de 8

En la figura 9 se ve el resultado del fenotipado con scimap con la tabla que se ve en la figura 8. Nótese particularmente que en ambos casos se marcan zonas etiquetadas en

el *ground truth* como tumorales como monocitos, lo cual es un error grave que hace que el fenotipado no sea aceptable.

Con el fin de comparar con el *ground truth* del que se dispone, se fenotipa según la tabla de fenotipado de la figura 10, que se corresponde al fenotipado realizado en el *ground truth*. Al comparar con los resultados obtenidos con scimap y el *ground truth* se obtienen la tabla de contingencia que se puede ver en la figura 11 y las métricas de clasificación que se pueden ver en la figura 12.

		CD16	CD8a	CD68	CD3	FoxP3	INSM1sc-271408	HLA_DR	CD4	Pan_Cytokeratin
All	Lymphoid	pos								
All	Macrophage	pos								
All	Tumour	anypos								
Lymphoid	T_cell	allneg							allneg	
Lymphoid	T_cytotoxic	allpos							allneg	
Lymphoid	CD4_T_cell	allneg							allpos	
Lymphoid	T_double	allpos							allpos	
CD4_T_cell	Treg	allpos								
CD4_T_cell	T_helper	allneg								

Figura 10: Tabla de fenotipado utilizada para comparar con el *ground truth*

		Cross Tab (scimap original vs. ground truth)											
phenotype_scimap	Macrophage	0.05	0.04	0.50	0.24	0.42	0.04	0.06	0.21	0.07	0.06	0.00	0.00
	T_double	0.00	0.00	0.00	0.00	0.00	0.03	0.09	0.14	0.06	0.17	0.00	0.00
	Tumour	0.95	0.96	0.50	0.76	0.58	0.93	0.86	0.66	0.86	0.77	1.00	1.00
		Lik_Macrophage	Lik_T_cytotoxic	Lik_T_double	Lik_T_helper	Macrophage	T_cell	T_cytotoxic	T_double	T_helper	T_reg	Tumour	Unassigned
		classification											

Figura 11: Tabla de contingencia del etiquetado por scimap contra el ground truth

	precision	recall	f1-score	support
Macrophage	0.812680	0.424699	0.557864	664.000000
T_cell	0.000000	0.000000	0.000000	297.000000
T_cytotoxic	0.000000	0.000000	0.000000	162.000000
T_double	0.050633	0.137931	0.074074	29.000000
T_helper	0.000000	0.000000	0.000000	399.000000
T_reg	0.000000	0.000000	0.000000	155.000000
Tumour	0.851024	1.000000	0.919517	7312.000000
accuracy	0.842537	0.842537	0.842537	0.842537
macro avg	0.244905	0.223233	0.221636	9018.000000
weighted avg	0.750031	0.842537	0.786879	9018.000000

Figura 12: Métricas de clasificación del etiquetado por scimap contra el ground truth

Como se puede ver, los resultados no se ajustan al *ground truth*. Todos los tipos linfoides desaparecen salvo *T_double*, y el tumor acapara la mayoría de las células de todos los fenotipos del *ground truth*. Si bien la precisión es relativamente alta, esto se debe fundamentalmente a la clase *Tumour*, que es mayoritaria y cuyas células sí se clasifican correctamente.

3.2. Clustering Jerárquico Supervisado

Uno de los posibles puntos de mejora de scimap es el umbralizado. El punto medio entre las medias de las componentes es arbitrario, la asunción de 3 componentes para el GMM no es válida en general, y realizar el cálculo de umbrales sobre todas las células añade ruido al modelo de GMM. Para solucionar este problema se plantean tres estrategias:

1. Mejorar el cálculo del umbral de scimap a partir de GMM, logrando que se corresponda a un umbral de clasificación óptimo bajo las hipótesis adecuadas.
2. Calcular los umbrales en las distintas etapas definidas por la tabla de fenotipado y no sobre el total de las células de la imagen. De esta manera se ajusta el modelo de GMM y se determina el umbral de positividad sobre las células que queremos diferenciar a través de esos marcadores.
3. Emplear clustering de Leiden sobre el conjunto de células y fenotipar los centroides de los clusters para suavizar los umbrales.

Por otro lado, se incluye una estrategia para clasificar a posteriori las células que no han encajado en ningún fenotipo inicialmente, a través de Random Forest. Esto permite que, aunque en algún caso los umbrales sean demasiado estrictos, las células no clasificadas inicialmente sí obtengan un fenotipo, siempre que dicha asignación sea robusta.

3.2.1. Modificación del cálculo de umbrales por GMM

En primer lugar, se modifica la selección del umbral de positividad. El algoritmo de scimap toma como umbral de positividad el punto medio entre la media de la normal correspondiente a la clase positiva y la mayor media de las normales de la clase negativa. Esto es muy sencillo y eficiente, pero no es un umbral razonable en algunos casos. Si las dos clases tienen desviaciones típicas muy distintas, con el fin de clasificar adecuadamente la mayor cantidad de células (asumiendo probabilidades iguales a priori), el umbral de positividad debería estar más cerca de la media de la normal menos dispersa. En la figura 13 se muestra un hipotético caso:





Figura 13: Caso de ejemplo de error en el umbral de positividad calculado por scimap

Por tanto, el código que se utiliza a lo largo del trabajo para la detección de positividad en cada uno de los marcadores incluye esta mejora; se toma el umbral de positividad como el umbral de clasificación óptimo entre la normal de mayor media y la de segunda mayor media, asumiendo probabilidades iguales a priori.

3.2.2. Fenotipado jerárquico

Uno de los inconvenientes técnicos de las imágenes de inmunofluorescencia múltiple, especialmente para tejidos tumorales, es el marcaje inespecífico. Algunos anticuerpos se adhieren de forma inespecífica a células que no presentan el marcador, especialmente a células tumorales. Un ejemplo en las imágenes que se han utilizado es la tinción inespecífica de CD8a en células tumorales. Esto supone un problema para el cálculo del umbral de positividad, ya que hay una población intermedia con valores de intensidad intermedios o incluso altos que dificulta el cálculo del umbral y da lugar a falsos positivos.

Para solventar este problema, al menos en aquellos marcadores que no se requieran en la primera etapa de fenotipado, se decide tomar los umbrales no sobre todas las células de la imagen, sino en cada etapa de fenotipado. De esta manera, en cada nodo de dicha etapa del árbol de decisión se calcula el umbral de positividad de los marcadores relevantes ajustando el GMM con únicamente los datos de las células que han llegado a dicho nodo. Por ejemplo, si se usa la tabla de la figura 8, el umbral de CD8a se calcularía cuando se llegue al nodo *Lymphoid*, y solo con las células que se hayan clasificado como *Lymphoid*, que son necesariamente positivas en CD3. En la figura 14 se ve la diferencia entre la distribución de CD8a sobre todas las células y sobre únicamente las linfoides.



(a) Intensidad media de CD8a sobre todas las células de la imagen

(b) Intensidad media de CD8a sobre las células linfoides (CD3+)

Figura 14: Diferencia en la distribución de CD8a sobre todas las células y sobre únicamente las linfoides de la imagen de ejemplo

3.2.3. Clustering de Leiden

Los datos celulares, aunque sean muy abundantes, tienden a presentar ciertos perfiles distintos que son identificables de forma no supervisada. Por ello es interesante realizar un clustering en los datos que agrupe esos perfiles.

Los distintos algoritmos de clustering que se han probado incluyen *K-means*, *DBSCAN* y clustering de Leiden. *K-means*, pese a su simplicidad, tiende a realizar unos agrupamientos que no encajan con los fenotipos esperados, probablemente porque los grupos que se pretenden identificar no son esféricos. Hay muchos grupos que vienen caracterizados por un nivel alto y similar en uno o varios marcadores, lo que no encaja con una región esférica para la distancia euclídea.

DBSCAN es un algoritmo muy potente, que detecta adecuadamente las formas complejas de los grupos que se pretenden detectar y señala los datos aislados. Llega a encajar muy bien con los datos, pero la necesidad de ajustar hiperparámetros como el radio de vecindad para cada región de interés de cada imagen no permite automatizar el proceso al nivel deseado. Sin embargo, el clustering de Leiden, basado en un grafo de vecindad, encaja satisfactoriamente con la estructura de los datos en las diferentes imágenes. Esto permite captar la cohesión local de los distintos fenotipos. La evaluación de los resultados se realiza de forma cualitativa, a través de un análisis visual de los clusters en la imagen y de los perfiles de intensidades medias de cada uno de los clusters.

El algoritmo de Leiden es un algoritmo de segmentación de comunidades en redes, así que antes de aplicarlo se construye un grafo de vecindad en los datos. Se elige un número de vecinos como parámetro $n_{neighbors}$, y se construye el grafo que incluye las aristas de cada nodo a sus $n_{neighbors}$ más cercanos, y sobre ese grafo se ejecuta el algoritmo de Leiden

de segmentación de comunidades.

El algoritmo de Leiden de segmentación de comunidades [13] es una modificación posterior del algoritmo de Louvain [14]. Ambos se basan en maximizar la modularidad de la segmentación. La fórmula de la modularidad de una segmentación es:

$$Q = \frac{1}{m} \sum_{i,j=1}^N \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j)$$

Siendo m el número de aristas, N el número de nodos, $A \in \mathcal{M}_{N \times N}$ la matriz de adyacencia en el grafo, k_i el grado del nodo i (o la suma de los pesos de sus enlaces, si el grafo es ponderado), $\delta(x, y) = 1$ si $x = y$, $\delta(x, y) = 0$ en otro caso, y c_i la comunidad del nodo i . Representa la diferencia de densidad interna en los clusters frente a la esperable aleatoriamente, fijados los grados de los nodos.

El algoritmo de Louvain comienza con la segmentación discreta, y consta de dos etapas que se repiten cíclicamente. La primera consiste en mover nodos de una comunidad a otra, y la segunda consiste en fusionar comunidades.

En la primera etapa se toman los nodos de uno en uno y se evalúa la mejora de la modularidad que se daría si el nodo se moviese a la comunidad de cada uno de sus vecinos (si el vecino no está en la misma comunidad). Esto se repite para todos los nodos, generando comunidades no aisladas. Nótese que el cálculo de este aumento de modularidad al mover un nodo i a la comunidad C es sustancialmente más ligero computacionalmente que calcular la modularidad de la nueva segmentación y restar. Basta usar la siguiente expresión:

$$\Delta Q = \left[\frac{\sum_{in} - k_{i,in}}{2m} - \left(\frac{\sum_{tot} + k_i}{2m} \right)^2 \right] - \left[\frac{\sum_{in}}{2m} - \left(\frac{\sum_{tot}}{2m} \right)^2 - \left(\frac{k_i}{2m} \right)^2 \right]$$

siendo:

- m : el número de aristas en toda la red
- $\sum_{in}$: la suma de los pesos de los enlaces internos del cluster C
- $\sum_{tot}$: la suma de todos los enlaces que inciden en cualquier nodo del cluster C
- k_i : la suma de los pesos de las aristas que inciden en el nodo i (el grado, en redes no ponderadas)
- $k_{i,in}$: la suma de los pesos que unen el nodo i con nodos del cluster C

La segunda fase consiste en construir una red cociente identificando las comunidades como nodos, y usando como pesos de los enlaces la suma de los pesos de enlaces entre nodos de las comunidades correspondientes, y repetir el proceso de la primera fase. Este proceso sobre red original supone una fusión de comunidades, cosa que es muy difícil de obtener en la primera fase, y resulta muy interesante para generar comunidades cohesionadas. Cuando se concluye esta segunda fase se repite la primera, y así sucesivamente. El algoritmo se detiene cuando no hay cambios en un ciclo completo, o si se llega a un límite máximo de ciclos.

El algoritmo tiene una complejidad de $\mathcal{O}(n \log(n))$, lo cual lo hace muy eficiente en redes grandes. Por supuesto, este algoritmo es voraz y no tiene la certeza de alcanzar un máximo global (ese es un problema NP-duro), aunque sí se alcanza un mínimo local, considerando, en el espacio de particiones, la noción de vecindad definida por las modificaciones posibles en la fase 1 o la fase 2.

El algoritmo de Leiden es una versión mejorada del algoritmo de Louvain, que resuelve algunos de los problemas del algoritmo de Leiden, fundamentalmente su gestión de la cola de nodos a evaluar en la fase 1 y la creación de comunidades desconectadas internamente o muy débilmente conectadas. Se puede ver en detalle en [13].

Nótese también que para ambos algoritmos la expresión de la modularidad que se utiliza en la implementación utilizada, de la librería `scanpy 1.11.5`, es la siguiente:

$$Q_\gamma = \frac{1}{m} \sum_{i,j=1}^N \left(A_{ij} - \gamma \frac{k_i k_j}{2m} \right) \delta(c_i, c_j)$$

siendo $\gamma \in (0, \infty)$ un parámetro llamado *resolución*. Para $\gamma = 1$ se obtiene la modularidad clásica. Para $\gamma < 1$ se reduce la penalización por incluir enlaces intra-comunidad inexistentes, con lo que se obtienen comunidades más grandes. Para $\gamma > 1$ ocurre exactamente lo contrario. Esto permite controlar el tamaño de las comunidades de la segmentación sin imponer el número de clusters de forma estricta.

En la figura 15 se ven 3 casos de clustering de Leiden sobre la imagen de ejemplo para distintos valores de los parámetros γ y k .




Figura 15: Resultados de clustering de Leiden para distintos valores de γ y k .

El clustering de Leiden se emplea en cada etapa de fenotipado sobre cada nodo, y se fenotipan con los umbrales calculados sobre todas las células de dicho nodo. Si bien no se desarrollará en este trabajo, sería interesante considerar el clustering y las intensidades medias por cluster como análisis exploratorio, sobre todo para detectar posibles fenotipos presentes en la imagen, que guíen a su vez la construcción de una tabla de fenotipado adecuada a la imagen.

3.2.4. Tratamiento de las células *Undefined*

En cada etapa de fenotipado, si una célula no encaja en ninguno de los posibles fenotipos de la subtabla, se marca como *Undefined*. Esto genera una cantidad significativa de células que deben clasificarse a posteriori. Sobre esas células, se filtran artefactos y se aplica un Random Forest para reclasificar.

Para comprobar si hay artefactos de segmentación, se utiliza el canal DAPI, que marca el núcleo de las células y se usa originalmente para la segmentación. Las células *Undefined* que tienen un nivel de DAPI anormalmente bajo se clasifican como artefactos, lo que las elimina de las indefinidas.

Para la reclasificación de las células indefinidas se construyen varios Random Forest usando como datos de entrenamiento las células que no son indefinidas, y usando validación cruzada para que los modelos sean distintos. Para cada célula se toman las predicciones de cada uno de los Random Forest. Si la predicción es unánime, se considera que el fenotipo es robusto y se clasifica la célula con ese fenotipo. En caso de que no haya unanimidad, se conserva como *Undefined*.

Nótese que, aunque es importante intentar clasificar todas las células en su fenotipo correcto, dejar células etiquetadas como *Undefined* no es necesariamente un error. La mayoría de tablas de fenotipado no son exhaustivas, y es posible que algunas de las células no pertenezcan a ninguno de los fenotipos que se etiquetan. Al mantener esta clase *Undefined*, se permite que un investigador revise dichas células y pueda encontrar fenotipos inicialmente no esperados, que son particularmente interesantes desde el punto de vista biológico.

3.2.5. Resumen e inconvenientes

Este primer algoritmo usa una tabla de fenotipado con el mismo formato que usa scimap, y se comienza con todas las células en la clase *All*. Se busca en la tabla aquellas filas en que el nodo de entrada sea *All*, y se construye una subtabla con solo esas filas. Esto es equivalente a considerar solo el fenotipado inicial en linajes.

Se fijan los umbrales de positividad ajustando un GMM para cada marcador presente en la subtabla. Se realiza un clustering de Leiden con los parámetros que se hayan predefinido y se clasifican los centroides de los clusters según los umbrales de positividad definidos sobre la población total. Se induce la clasificación de los centroides a las células individuales, y sobre cada uno de los linajes se repite el proceso: se construye la subtabla, se clusteriza y se clasifican los centroides, y sobre cada uno de los fenotipos resultantes que aparezcan como nodo de entrada en la tabla también se repite el proceso.

Este primer algoritmo resuelve varios de los inconvenientes de scimap. El cálculo de umbrales es más preciso, y el tratamiento de indefinidas permite evitar casos que ocurrían con scimap en que la mayoría de la población quedaba como *Undefined* al elevar demasiado los umbrales.

Sin embargo, el clustering, que parece suavizar umbrales al evitar que grupos coheridos tengan fenotipos diferentes, incluye grupos pequeños dentro de clusters a los que no pertenecen. Un ejemplo es en la imagen de ejemplo, las células linfoides que se encuentran

dentro de una zona tumoral proliferativa. Al estar dentro de la zona tumoral, tienen un nivel alto de marcadores tumorales, y en general tienen un perfil de intensidades similar al de las células adyacentes, salvo por una intensidad alta en CD3 y CD4 o CD8a. Además, son un grupo muy pequeño, de menos de 10 células, con lo que quedan incluidas dentro de un cluster tumoral más grande, cuyo centroide se clasifica como tumor proliferativo. No detectar este tipo de células es muy relevante para la interpretación de los resultados.

Por otro lado, se mantiene fijo el número de componentes de GMM para todos los marcadores, independientemente de su distribución. Esto limita la capacidad de ajuste del GMM para obtener un umbral adecuado a la distribución de cada marcador.

3.2.6. Resultados y evaluación

En las siguientes figuras se ven las gráficas obtenidas al comparar los resultados del fenotipado a través del algoritmo de Clustering Jerárquico Supervisado con el *ground truth*. En la tabla de contingencia de la figura 16 se ve que hay un nivel de acierto razonable, con confusiones fundamentalmente entre los tipos celulares linfoides. La matriz de intensidades por clase de la figura 17 no resulta muy informativa, lo cual es esperable al no incluir fenotipos que están presentes en la imagen. Las métricas de clasificación globales y por clase se pueden ver en la figura 18, con unos resultados sustancialmente mejores que los obtenidos con el algoritmo base de *scimap*.

Cross Tab (scimap original vs. ground truth)

	Lik_Macrophage	Lik_T_cytotoxic	Lik_T_double	Lik_T_helper	Macrophage	T_cell	T_cytotoxic	T_double	T_helper	T_reg	Tumour	Undefined
CD8_T_cell	0.00	0.06	0.00	0.00	0.00	0.23	0.62	0.55	0.01	0.00	0.00	0.00
Macrophage	0.99	0.23	0.50	0.22	0.58	0.04	0.05	0.10	0.03	0.01	0.12	0.12
T_cell	0.00	0.15	0.00	0.00	0.00	0.21	0.25	0.00	0.05	0.01	0.00	0.01
T_double	0.00	0.00	0.00	0.00	0.00	0.03	0.06	0.00	0.01	0.01	0.00	0.00
T_helper	0.00	0.00	0.50	0.63	0.09	0.39	0.01	0.14	0.74	0.63	0.00	0.05
Treg	0.00	0.00	0.00	0.02	0.00	0.05	0.00	0.21	0.15	0.34	0.00	0.00
Tumour	0.00	0.26	0.00	0.01	0.00	0.02	0.00	0.00	0.00	0.00	0.84	0.22
Undefined_	0.00	0.30	0.00	0.09	0.14	0.03	0.00	0.00	0.01	0.00	0.02	0.19
Undefined_All	0.00	0.00	0.00	0.01	0.00	0.00	0.01	0.00	0.00	0.00	0.00	0.01
Artifact	0.01	0.00	0.00	0.03	0.19	0.00	0.00	0.00	0.00	0.00	0.01	0.39

classification

Figura 16: Tabla de contingencia, normalizada por columnas, de los resultados de Clustering Jerárquico Supervisado contra el *ground truth*




Figura 17: Gráfica con las intensidades medias relativas de los canales según fenotipo en los resultados de Clustering Jerárquico Supervisado contra el *ground truth*

	precision	recall	f1-score	support
T_cytotoxic	0.621359	0.395062	0.483019	162.000000
T_cell	0.485876	0.289562	0.362869	297.000000
Macrophage	0.494681	0.980422	0.657576	664.000000
T_helper	0.553061	0.679198	0.609674	399.000000
T_reg	0.414894	0.503226	0.454810	155.000000
T_double	0.015873	0.034483	0.021739	29.000000
Tumour	0.997233	0.887309	0.939065	7312.000000
micro avg	0.863847	0.847084	0.855383	9018.000000
macro avg	0.511854	0.538466	0.504107	9018.000000
weighted avg	0.903819	0.847084	0.865323	9018.000000

Figura 18: Métricas de clasificación multiclase para el Clustering Jerárquico Supervisado

3.3. Fenotipado jerárquico con GMM según BIC

La eliminación del clustering es sencilla, basta fenotipar las células según sus propias intensidades individuales. Sin embargo, el método de elección del número de componentes del GMM no es unívoco ni sencillo.

3.3.1. Elección del número de componentes por BIC y D de Ashman

Se consideraron y se hicieron pruebas imponiendo unos porcentajes de positividad máximos y mínimos, que se descartaron al considerarse que imponían unas hipótesis muy restrictivas, evaluando la calidad de los canales en base a métricas de la imagen, y finalmente usando criterios de información, tanto AIC como BIC, que acaban siendo lo más adecuado.

La idea básica es, como resulta natural, minimizar el BIC. Sin embargo, se incluye un tratamiento particular de algunas distribuciones de GMM que no justifican el umbralizado. A la hora de determinar un umbral, si la componente positiva y la inmediatamente

anterior tienen medias muy cercanas, lo más probable es que el modelo no esté separando adecuadamente dos poblaciones, sino que esté usando ambas campanas para ajustar mejor la distribución de una sola población, ya sea positiva o negativa. En la figura 19 se pueden ver dos ejemplos. Estos casos no son útiles para el cálculo del umbral, y por tanto se descartarán, independientemente de su valor de BIC.




Figura 19: Ejemplos de resultados de GMM que no son útiles.

La condición empleada para determinar si las medias m_{neg} y m_{pos} de las dos distribuciones están demasiado cercanas se basa en la distancia de Ashman [1]. La fórmula de esta distancia entre distribuciones es la siguiente:

$$D = \sqrt{2} \frac{|\mu_1 - \mu_2|}{\sqrt{\sigma_1^2 + \sigma_2^2}}$$

En el caso de que ambas distribuciones tengan la misma desviación típica se simplifica a la distancia entre las medias dividida por la desviación típica, lo cual resulta simple y razonable, y es invariante a cambios de escala. Para definir un umbral se elige $D = 2$. Si $D = 2$, y las desviaciones típicas son iguales la función de densidad conjunta f es constante entre ambas medias, i.e., $f(x) = f(y), \forall x, y \in [\mu_1, \mu_2]$. Si $D > 2$, f es convexa en (μ_1, μ_2) , lo que se corresponde a un 'valle' en la función de densidad, y la función de densidad es bimodal. Si $D < 2$, f es cóncava en (μ_1, μ_2) , con lo que la distribución tiene forma de 'campana' en ese intervalo y es unimodal, con lo que no es razonable fijar un umbral en ese intervalo. En la figura 20 se ven ejemplos de los tres casos.




Figura 20: Ambas distribuciones normales y su conjunta para distintos valores de D

Si ninguno de los valores de $k > 1$ considerados separa adecuadamente la clase positiva, o si $k = 1$ obtiene el menor BIC, se asume que la distribución es unimodal, con el grueso de la población en los negativos, y los positivos serán valores altos. De forma

provisional se utiliza el umbral $\mu + r\sigma$, siendo μ la media de la normal que aproxima los datos, y σ su desviación típica. El valor de r es un parámetro que se puede modificar, por defecto fijado en $r = 1,5$.

3.3.2. Resultados e inconvenientes

Con estos cambios se llega a unos resultados más satisfactorios. Sin embargo, al realizarse una revisión detallada del fenotipado directamente sobre la imagen se encuentra un nuevo problema. En algunas células los datos tabulares extraídos de la imagen no son representativos para algunas células. Esto se debe a dos fenómenos diferentes.

En primer lugar, la segmentación realizada inicialmente es sobre el canal DAPI, que detecta únicamente el núcleo celular, y se realiza una expansión artificial sobre dicha segmentación del núcleo, con el fin de incluir dentro de la máscara de segmentación el citoplasma y la membrana de la célula. Con el fin de incluir la totalidad de la célula en dicho polígono, y dado que la distancia de expansión es la misma para todas las células, se toma una expansión que es excesiva en algunos casos. Por tanto, hay polígonos de la segmentación que incluyen, además de la célula, una proporción considerable de fondo de la imagen. Esto disminuye sustancialmente las intensidades medias de muchos marcadores en esa célula, pues el fondo no tiene tinción. En la figura 21 se observa un caso concreto con dos células adyacentes, ambas *CD8₊ T_H cell*. La célula situada a la izquierda, si bien incluye bastante fondo en la máscara, sí alcanza positividad en CD8a, así que es etiquetada adecuadamente. La de la derecha, al tener una mayor proporción de fondo, cae por debajo del umbral de positividad para CD8a y es etiquetada incorrectamente. Sin embargo, ambas tienen un nivel real de CD8a similarmente alto.






Figura 21: Ejemplo de exceso de fondo en la máscara de segmentación. CD3 en verde, CD8a en rojo.

En segundo lugar, algunos polígonos de segmentación incluyen fragmentos de células adyacentes, lo que aumenta la intensidad media de marcadores en los que las células adyacentes son positivas, sea o no positiva la célula en cuestión. Esto lleva a considerar maneras de evaluar la coexpresión de los marcadores a nivel espacial dentro de cada célula, i.e., que las intensidades altas de varios marcadores coincidan en las mismas zonas dentro de la célula. Por ejemplo, en la figura 22 se ven dos casos muy diferentes, ambos

etiquetados como *CD8_T_cell*. En el primero se ve que las intensidades altas de CD3 están en una zona aislada al borde de la célula, y el nivel alto en CD8a es más uniforme en la célula, debido a un marcaje inespecífico en zona tumoral. Esta célula no debería ser etiquetada como *CD8_T_cell*. En el segundo caso se ve una *CD8_T_cell* correctamente etiquetada, en la que CD3 y CD8a se expresan en la misma zona.



(a) Célula tumoral etiquetada incorrectamente como *CD8_T_cell*.



(b) *CD8_T_cell* etiquetada correctamente.

Figura 22: Dos ejemplos de células etiquetadas como *CD8_T_cell*, con CD3 en verde y CD8a en rojo.

En ambos casos el error no proviene del algoritmo de fenotipado a partir de los datos tabulares, sino de la obtención de dichos datos a partir de la imagen. Al pasar de agregar según la media a según la mediana no se obtienen mejoras significativas. En los casos en los que la máscara de la célula está conformada por un 40-60 % de fondo los resultados empeoran, y también empeora los resultados para algunos marcadores de membrana, los cuales, en el caso ideal, se adhieren únicamente a la membrana de las células positivas, lo que resulta en un aro iluminado en el borde de la célula. Como ese aro no ocupa la mayoría de la célula, la mediana devuelve valores más bajos para las células verdaderamente positivas.

3.4. Fenotipado a través de regiones subcelulares

Para resolver ambos problemas, tanto máscaras celulares excesivamente grandes como problemas de colocalización de marcadores se implementan dos modificaciones distintas. Para reducir el problema de las máscaras se incluye un recorte a través de un modelo de GMM sobre la suma de todos los canales de la imagen, y para la cuestión de la colocalización se implementa una estrategia de fenotipado en regiones celulares.

3.4.1. Recorte de máscaras celulares

Para recortar máscaras celulares se considera la suma de todos los canales disponibles, habiendo descartado aquellos que se consideren defectuosos, y se ajusta un modelo de GMM sobre las intensidades píxel a píxel de dicha suma de canales. Se verifica la validez de $k = 3$ componentes a través de la distancia D de Ashman. En caso de no pasar esta comprobación, se comparan $k = 2$ y $k = 4$ según su BIC. En las imágenes estudiadas

$k = 3$ pasa siempre la comprobación, ya que el modelo con una componente más a la izquierda, claramente fondo, una componente intermedia formada por tinciones inespecíficas sobre fibras, probablemente de colágeno, y una componente a la derecha formada por células claras, con las tres componentes bien separadas.

Nótese que, dado que los diferentes marcadores tienen distintas escalas es probable que exista una mejor forma de obtener un único canal con el fin de determinar el fondo. Una propiedad útil de la suma directa de los canales es que, dado que el DAPI tiene un rango de intensidad bastante más alto que los demás marcadores, ningún píxel de núcleo queda en las componentes más a la izquierda. Se incluye la posibilidad de colocar el umbral entre la primera y la segunda componente o entre la última y la penúltima.

Una vez se ha determinado el umbral, para cada célula, se convierte su polígono de segmentación en una máscara de píxeles. Se verifica si hay píxeles de la máscara que estén por debajo del umbral global. Si todos los píxeles de la célula tienen una intensidad mayor que el umbral, el polígono de la célula se conserva intacto. Si hay píxeles de la máscara cuya intensidad está por debajo del umbral, se considera que hay fondo incluido en la máscara y se debe recortar. Para ello se ajusta de nuevo un GMM con 3 componentes con las intensidades en el canal suma de los píxeles de la máscara, se fija un umbral entre la primera y la segunda componente y se eliminan de la máscara de la célula los píxeles por debajo de dicho umbral. Finalmente se convierte la máscara a polígono, se descartan las pequeñas regiones no conexas y se rellenan los agujeros que se puedan haber generado. El beneficio que aporta este segundo ajuste célula a célula es asegurar la coherencia local y evitar pequeños desajustes al usar el umbral global, además de impedir que se descarten las células que estén enteramente por debajo del umbral global.

En los casos de los que se dispone parece que considerar solo la última componente como positiva para calcular el umbral global da mejores resultados, ya que, si se consideran como positivas todas las componentes salvo la primera, se recortan muy pocos polígonos y el problema de las máscaras que incluyen fondo sigue estando presente. No se han detectado células que se recorten de forma excesiva al utilizar esta estrategia, pero es un posible riesgo.

En la figura 23 se ve la distribución del canal suma y el recorte concreto que se realiza sobre algunas células, según las componentes que se consideren positivas sobre el canal suma.




Figura 23: Gráficas del recorte de polígonos en la imagen de ejemplo. En las figuras 23b y 23c, en rojo se muestra la suma de todos los canales.

3.4.2. Fenotipado a través de regiones subcelulares

Con el objetivo de lidiar con el problema de la colocalización y la inclusión de células adyacentes en la máscara, lo cual no queda resuelto al recortar las máscaras, se modifica la estrategia de fenotipado. En vez de obtener un valor de intensidad para cada par de célula y marcador, se decide dividir cada célula en regiones, otorgar un fenotipo a cada una de estas regiones y obtener un fenotipo para toda la célula a partir de los fenotipos de las regiones. Por ejemplo, en el caso de la figura 22a, solo se fenotipará incorrectamente la región en la que aparece la tinción de CD3, y el resto de las regiones de la célula se fenotiparán correctamente como tumor, y al obtener un fenotipo global la célula será fenotipada como tumoral.

Se comienza dividiendo cada célula en regiones. Para ello se emplea un clustering aglomerativo con restricciones de conectividad. El algoritmo, que está disponible en `sklearn.cluster` en la versión 1.8.0 de `scikit-learn`, coincide exactamente con el habitual clustering aglomerativo, y se añade la restricción de que no se permite unir dos clusters si no existe un par de píxeles, uno de cada cluster, que sean adyacentes según la matriz de adyacencia que se define, en la que se consideran adyacentes los píxeles que comparten un lado y no los que comparten una esquina. Como distancia entre clusters se emplea el criterio de mínima varianza de Ward.

Para decidir en qué etapa cortar el dendrograma, y en consecuencia en cuántas regiones se divide la célula, se utiliza el criterio de máxima supervivencia, dentro de un rango de número de clusters razonable, por defecto de 2 a 10. Para entender este criterio es necesario definir d_k la distancia de Ward entre los dos clusters que se unen para pasar de k clusters a $k - 1$, y definir la supervivencia (*lifespan*) de dicha configuración como $l_k := d_k - d_{k+1}$.

Si para cada valor $d \geq 0$ ejecutásemos un clustering aglomerativo y concluyésemos cuando la menor distancia entre clusters fuese mayor que d , tendríamos una aplicación $f : [0, \infty) \rightarrow \mathbb{N}$ que le otorga a cada d el número de clusters de la partición del conjunto de píxeles que define. Para cada k , $f^{-1}(k)$ es un intervalo, y la supervivencia l_k es la longitud de dicho intervalo. En consecuencia, la supervivencia se puede entender como una medida de robustez del clustering correspondiente, y al elegir el k que obtiene una mayor supervivencia se está eligiendo un clustering robusto y no arbitrario. En la figura 24 se ve el resultado de la división en regiones subcelulares de las células de la figura 21.




Figura 24: Regiones subcelulares de las células de la figura 21.

Una vez que se han definido las regiones, se agrega en cada región según la media, y se fenotipan las regiones usando el mismo algoritmo de 3.3, ajustando los umbrales sobre las intensidades por regiones y fenotipando estas mismas regiones. Nótese que, al haberse obtenido por clustering, las regiones son generalmente bastante uniformes, y los resultados agregando según la mediana son muy parecidos a los obtenidos usando la media. Dado que calcular la media parece computacionalmente menos costoso se opta por esa estrategia.

Para obtener un fenotipo global por célula se incluye inicialmente un mecanismo sencillo de votación. Para cada fenotipo presente en la célula, se suman las áreas de cada una de las regiones a las que se ha otorgado ese fenotipo, y el resultado se considera como la puntuación de dicho fenotipo. Se toma como fenotipo de la célula aquel que tenga mayor puntuación.

Esto da unos resultados bastante buenos, pero resulta algo simplista, sin tomar en cuenta los posibles fenotipos que no han resultado ganadores en el fenotipado subcelular. Por tanto se incluye en la versión modificada de `phenotype_cells` de `scimap` la posibilidad de devolver las puntuaciones de cada uno de los fenotipos, y se desarrolla la obtención de unas puntuaciones representativas para cada fenotipo a partir de las puntuaciones de `phenotype_cells` para cada etapa de fenotipado.

Obtener esas puntuaciones globales a lo largo de todo el fenotipado presenta dos problemas. En primer lugar, al disponer de las puntuaciones para cada etapa y no de una puntuación única para cada fenotipo, hay que generar una única puntuación a partir de las puntuaciones de las distintas etapas, asegurando que la puntuación más alta se corresponda al fenotipo ganador según `phenotype_cells`.

En segundo lugar, hay muchos fenotipos finales para los que una región no habrá recorrido todas las etapas de la tabla de fenotipado. Por ejemplo, consideremos de nuevo la tabla de la figura 8 y una región que ha sido fenotipada finalmente como *CD8_T_cell*. Entonces esa célula habrá comenzado en el nodo *All*, y entre *Tumour*, *Lymphoid*, *Myeloid* y *Stroma* habrá sido etiquetada como *Lymphoid*. En una segunda etapa, entre *CD8_T_cell* y *CD4_T_cell*, el fenotipo ganador habrá sido *CD8_T_cell*. Al no haber sido etiquetada como *Tumour*, no tendrá una puntuación para los subtipos de *Tumour*.

Para obtener una puntuación general de cada uno de los fenotipos en las regiones se emplea la media de las puntuaciones de las etapas, con la restricción añadida de que se limita las puntuaciones de los fenotipos que no son el ganador a ser menores o iguales que la puntuación del fenotipo ganador menos 0,01, lo que asegura que el fenotipo ganador tenga la mayor puntuación. Para los fenotipos que no llegan a evaluarse se copia la puntuación del último fenotipo evaluado de su rama del árbol. En el caso de las regiones que quedan como *Undefined* inicialmente y son reetiquetadas por unanimidad en los Random Forest se utilizan como puntuaciones de los distintos fenotipos las probabilidades de predicción medias de cada clase en los Random Forests. En la figura 25 se ve el recorte en regiones de una célula particular y las puntuaciones asociadas a cada una de sus regiones. Nótese que la región con identificador 600706 ha sido reetiquetada con Random Forest.




Figura 25: Regiones subcelulares y puntuaciones asignadas a cada uno de los fenotipos.

Para obtener un fenotipo para toda la célula se suman las puntuaciones de cada fenotipo en cada zona, ponderando por el área, y se conserva únicamente el máximo. Se implementó la posibilidad de incluir un coeficiente según la posición de la región, con el objetivo de que los marcadores de membrana fuesen más relevantes cuanto más cerca del borde de la célula se expresen. Sin embargo, la segmentación no es suficientemente precisa ni la tinción es suficientemente nítida en muchos canales para que supusiese una mejora.

Por último, se realiza una última etapa de fenotipado. Esto se debe a que algunos marcadores no deben colocalizar con los demás, sino que deben expresarse específicamente en el núcleo. A estos marcadores se les denomina *de estado* o *funcionales*, y sirven para distinguir, dentro de los fenotipos algunos estados de la célula. Por ejemplo, el Ki_67 es un marcador que indica si una célula está en proceso de mitosis.

Para distinguir el nivel de intensidad de estos marcadores en el núcleo de la célula se utiliza una segmentación del núcleo si viene dada, y en caso contrario se genera una de forma análoga a la estrategia de recorte de los polígonos de segmentación celular explicada previamente, usando el canal DAPI en vez de la suma de todos los canales. Sobre los núcleos se calculan las intensidades medias de los marcadores de estado, y a partir de estos datos y de la tabla de fenotipado correspondiente, se calculan los umbrales sobre las poblaciones que correspondan y se fenotipa.

Dado que se requiere dividir el fenotipado en dos etapas, se añade una columna a la tabla, que indica, para cada fila, si corresponde a la primera etapa de fenotipado (linaje)

o a la segunda (estado). En la figura 26 se ve la tabla utilizada durante el desarrollo del algoritmo.

Phase	Unnamed: 1	Unnamed: 2	CD8a	CD68	Ki_67	CD163	CD3	CD274	Chromogranin_A	FoxP3	INSM1sc-271408	HLA_DR	CD4	CD11b	Pan_Cytokeratin	Actin	CD31
Lineage	All	Lymphoid					pos										
Lineage	All	Myeloid		anypos										anypos			
Lineage	All	Stroma														anypos	anypos
Lineage	All	Tumour							anypos		anypos				anypos		
Lineage	Lymphoid	CD8_T_cell	pos										neg				
Lineage	Lymphoid	CD4_T_cell	neg										pos				
Lineage	Myeloid	Monocyte												pos			
Lineage	Myeloid	Macrophage		pos													
Lineage	Macrophage	M1_Macrophage				neg							pos				
Lineage	Macrophage	M2_Macrophage				pos							neg				
Lineage	Stroma	Endothelial															pos
Lineage	Stroma	Fibroblast															pos
State	CD4_T_cell	T_reg								pos							
State	CD4_T_cell	T_helper								neg							
State	Tumour	Proliferative_Tumour			pos												
State	Tumour	Non_Proliferative_Tumour			neg												

Figura 26: Tabla de fenotipado dividida en etapas *Lineage* y *State*.

3.4.3. Resultados e inconvenientes

Este algoritmo resulta en un fenotipado correcto para la mayoría de las células, lo cual es satisfactorio, particularmente teniendo en cuenta la dificultad del problema, tanto a nivel de planteamiento como de calidad de los datos.

A nivel de inconvenientes generales se detecta inicialmente una sensibilidad algo excesiva hacia tumor. Por otro lado, al elegir el fenotipo de cada célula comparando las puntuaciones, no se genera una clase de células indefinidas. Para solventar este problema se añade una estrategia sencilla: se añade, tras reetiquetar las regiones indefinidas con Random Forest, se otorga al fenotipo *Undefined* una puntuación igual a la diferencia entre 1 y el máximo de las demás puntuaciones para cada célula. De esta forma sí se generan células *Undefined* de forma adecuada.

Otro problema es la complejidad computacional. Recortar las células individuales y dividir las en regiones es relativamente costoso, suponiendo aproximadamente 10 minutos de tiempo de ejecución cada una de estas dos etapas sobre la imagen de ejemplo, que consta de unas 15000 células. Si no se ha segmentado el núcleo, ese cálculo supone aproximadamente ese mismo tiempo. En total, esto supone que el proceso total, incluyendo la segmentación del núcleo, puede alcanzar unos 35 minutos para un ordenador portátil con 32 GB de RAM. Esto no impide que sea aplicable, pero sí es un inconveniente en comparación con otros algoritmos.

A continuación se ven los resultados obtenidos al comparar el fenotipado con el *ground truth*. En la figura 27 se ve la tabla de contingencia, en la figura 28 se ven las intensidades por marcador y clase, y en la figura 29 se ven las métricas de clasificación.




Figura 27: Tabla de contingencia, normalizada por columnas, de los resultados finales contra el *ground truth*




Figura 28: Gráfica con las intensidades medias relativas de los canales según fenotipo en los resultados finales contra el *ground truth*

	precision	recall	f1-score	support
T_cytotoxic	0.631579	0.740741	0.681818	162.000000
T_cell	0.678082	0.333333	0.446953	297.000000
Macrophage	0.839018	0.926205	0.880458	664.000000
T_helper	0.582677	0.741855	0.652701	399.000000
T_reg	1.000000	0.154839	0.268156	155.000000
T_double	0.324324	0.413793	0.363636	29.000000
Tumour	0.992626	0.994119	0.993372	7312.000000
micro avg	0.941301	0.935352	0.938317	9018.000000
macro avg	0.721187	0.614984	0.612442	9018.000000
weighted avg	0.944310	0.935352	0.931903	9018.000000

Figura 29: Métricas de clasificación de los resultados finales contra el *ground truth*

De nuevo, parece que hay bastante confusión entre tipos linfoides, y la falta de ciertas clases para ajustarse al *ground truth* se ve representada en las intensidades medias por clase.




Figura 30: Distribución espacial de las células coloreadas según el fenotipo final.

4. Resultados

Los resultados que se obtienen sobre las imágenes de prueba son satisfactorios tanto en las métricas como en el análisis experto. Hay algunos problemas con algunos canales en otras regiones de interés por la calidad de la imagen. También hay algunos problemas en casos de marcadores cuya distribución es claramente unimodal. En esos casos, como se explicaba en 3.3.1, se fija el umbral de positividad según la media y la desviación típica de la única normal ajustada. De cara a permitir correcciones de pequeños errores como este que se deben al umbralizado, se incluye también la posibilidad de definir el umbral manualmente.

A continuación se ven los resultados obtenidos usando la tabla de fenotipado completa:

Cross Tab (Algoritmo final vs. ground truth)

final_phenotype	Endothelial	0.02	0.03	0.01	0.00	0.01	0.00	0.03	0.05
	Fibroblast	0.04	0.05	0.01	0.00	0.03	0.01	0.02	0.15
	M1_Macrophage	0.17	0.00	0.01	0.00	0.02	0.00	0.00	0.01
	M2_Macrophage	0.00	0.00	0.00	0.00	0.00	0.01	0.00	0.00
	Monocyte	0.02	0.01	0.01	0.03	0.02	0.00	0.01	0.01
	Non_Proliferative_Tumour	0.01	0.06	0.02	0.00	0.03	0.00	0.61	0.39
	Proliferative_Tumour	0.01	0.01	0.00	0.00	0.00	0.00	0.32	0.05
	T_cytotoxic	0.00	0.13	0.62	0.17	0.00	0.00	0.00	0.00
	T_helper	0.00	0.24	0.01	0.24	0.74	0.63	0.00	0.00
	T_reg	0.00	0.00	0.00	0.03	0.00	0.32	0.00	0.00
	Undefined_	0.73	0.46	0.30	0.52	0.17	0.03	0.01	0.34
		Macrophage	T_cell	T_cytotoxic	T_double	T_helper	T_reg	Tumour	Unassigned
		classification							

Figura 31: Tabla de contingencia, normalizada por columnas, de los resultados finales con tabla de fenotipado completa contra el *ground truth*




Figura 32: Gráfica con las intensidades medias relativas de los canales según fenotipo en los resultados finales con tabla de fenotipado completa contra el *ground truth*




Figura 33: Distribución espacial de las células coloreadas según el fenotipo final.

El inconveniente que se sigue detectando en algunos marcadores es que la clase positiva no está compuesta únicamente por la componente más a la derecha, sino por dos o más componentes del GMM. Esto lleva a que el umbral de positividad sea más alto de lo debido, y causa problemas en algunos casos. EL otro problema, análogo a este primero, se

da en el caso en que el modelo ganador, ya sea por BIC o por criterio de separación, es el obtenido con una única componente. En estos casos, el marcador tiene una distribución unimodal y el umbral no se ajusta adecuadamente.




Figura 34: Ejemplo de ajuste inadecuado por haber 2 componentes positivas.




Figura 35: Ejemplo de ajuste inadecuado por haber una sola componente.

Sin embargo, es importante recordar la dificultad de este problema. La mIF es todavía una técnica en desarrollo que tiene margen de mejora a nivel de calidad y uniformidad de las imágenes producidas, y el problema del fenotipado no es un problema supervisado de clasificación, sino un problema no supervisado en el que el conocimiento previo viene dado por la tabla de fenotipado.

El código y un notebook de prueba se puede encontrar en este repositorio de GitHub.

5. Conclusión

La inmunofluorescencia múltiple es una tecnología reciente que todavía se sigue desarrollando. Los algoritmos de fenotipado siguen siendo un tema por explorar, y tienen mucho margen de mejora, con múltiples enfoques y estrategias en desarrollo con el fin de automatizar este proceso.

A lo largo del trabajo se han desarrollado sucesivos algoritmos de fenotipado en imágenes de mIF, comenzando con un análisis detallado del algoritmo de fenotipado de `scimap` 2.3.5 [8]. A este primer algoritmo se le modifica el cálculo del umbral de positividad por GMM y se incluye clustering de Leiden, fenotipado jerárquico sobre los clusters y un algoritmo para el reetiquetado de células indefinidas. Al perderse poblaciones por el clustering se elimina, y se mejora el cálculo del umbral, incluyendo un sistema de elección del número de componentes de GMM según BIC con un criterio de separación en base a la D de Ashman. Finalmente, para lidiar con los problemas de coexpresión de marcadores y de segmentación se implementa un sistema de recortado de polígonos de segmentación y un sistema de fenotipado por regiones.

El resultado final es un algoritmo de fenotipado que lidia con múltiples de los problemas que presentan las imágenes de mIF en general y las imágenes de SCLC en particular, fundamentalmente las tinciones inespecíficas, las diferencias de escala entre los diferentes canales y los problemas derivados de la segmentación a nivel celular.

Como posibles líneas a seguir, me gustaría destacar cuatro de ellas. En primer lugar, la más natural es, a partir de los datos generados en el fenotipado, incluir medidas espaciales que puedan usarse directamente por los expertos para extraer conclusiones a nivel biológico.

En segundo lugar, sería interesante introducir una cierta evaluación de la calidad de los canales de forma automática. Por la naturaleza de la tinción de tejidos, de los marcadores y de la cámara digital que detecta la fluorescencia, hay algunos ciclos que resultan defectuosos. Esto obliga a revisar manualmente esos canales, y elegir si descartarlos o conservarlos para el fenotipado. La automatización de ese proceso a partir de medidas estadísticas de la imagen parece tanto viable como potencialmente útil.

En tercer lugar, sería interesante probar otras estrategias de fenotipado no basadas en `scimap`. Hay otros proyectos interesantes que utilizan enfoques muy variados, desde redes neuronales profundas (DeepCell) hasta un enfoque bayesiano (TracerX-PHLEX) pasando por fenotipado píxel a píxel (Pixie). Cada uno de estos enfoques tienen sus ventajas y sus inconvenientes, y serían potencialmente útiles para las imágenes de SCLC que se han utilizado a lo largo de este trabajo.

En cuarto y último lugar, el clustering de Leiden parece mostrar potencial, tanto para el análisis exploratorio como para el fenotipado. Los clusters tienden a detectar correctamente los fenotipos, salvo grupos muy pequeños. Este inconveniente lleva a descartarlo durante el desarrollo del algoritmo, pero se podría intentar afrontar de otra manera, por ejemplo extrayendo las células atípicas dentro de cada cluster a través de Isolation Forest y fenotipando esas células individualmente. Como análisis exploratorio también puede ser interesante para diseñar tablas y detectar fenotipos presentes en base a la tabla de

intensidades medias por cluster para los distintos marcadores.

Referencias

- [1] Keith A. Ashman, Christina M. Bird, and Stephen E. Zepf. Detecting bimodality in astronomical datasets. *The Astronomical Journal*, 108:2348, December 1994.
- [2] Quentin Blampey, Kevin Mulder, Margaux Gardet, Stergios Christodoulidis, Charles-Antoine Dutertre, Fabrice André, Florent Ginhoux, and Paul-Henry Cournède. Sopa: a technology-invariant pipeline for analyses of image-based spatial omics. *Nature Communications*, 15(1):4981, 2024.
- [3] Freddie Bray, Mathieu Laversanne, Hyuna Sung, Jacques Ferlay, Rebecca L. Siegel, Isabelle Soerjomataram, and Ahmedin Jemal. Global cancer statistics 2022: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, apr 2024.
- [4] L. Marconato, G. Palla, and K.A. et al. Yamauchi. Spatialdata: an open and universal data framework for spatial omics. *Nature Methods*, 2024.
- [5] Z. Megyesfalvi, C. M. Gay, H. Popper, R. Pirker, G. Ostoros, S. Heeke, C. Lang, K. Hoetzenecker, A. Schwendenwein, K. Boettiger, P. A. Bunn, F. Renyi-Vamos, K. Schelch, H. Prosch, L. A. Byers, F. R. Hirsch, and B. Dome. Clinical insights into small cell lung cancer: Tumor heterogeneity, diagnosis, therapy, and future directions. *CA: A Cancer Journal for Clinicians*, 73(6):620–652, 2023.
- [6] D. Millrine, K. L. Simpson, F. Blackhall, and C. Dive. Small-cell lung cancer: anatomy of an immune-cold tumor. *Trends in Cancer*, mar 2026.
- [7] B. Y. Nabat, H. Hamidi, M. C. Lee, R. Banchereau, S. Morris, L. Adler, V. Gayevskiy, A. M. Elhossiny, M. K. Srivastava, N. S. Patil, K. A. Smith, R. Jesudason, C. Chan, P. S. Chang, M. Fernandez, S. Rost, L. M. McGinnis, H. Koeppen, C. M. Gay, J. D. Minna, J. V. Heymach, J. M. Chan, C. M. Rudin, L. A. Byers, S. V. Liu, M. Reck, and D. S. Shames. Immune heterogeneity in small-cell lung cancer and vulnerability to immune checkpoint blockade. *Cancer Cell*, Mar 2024.
- [8] Ajit J. Nirmal and Peter K. Sorger. Scimap: A python toolkit for integrated spatial analysis of multiplexed imaging data. *Journal of Open Source Software*, 9(97):6604, 2024.
- [9] Marius Pachitariu, Michael Rariden, and Carsen Stringer. Cellpose-sam: superhuman generalization for cellular segmentation. *bioRxiv*, 2025.
- [10] E. Redin, Á. Quintanal-Villalonga, and C. M. Rudin. Small cell lung cancer profiling: an updated synthesis of subtypes, vulnerabilities, and plasticity. *Trends in Cancer*, oct 2024.
- [11] C. M. Rudin, E. Brambilla, C. Faivre-Finn, and J. Sage. Small-cell lung cancer. *Nature Reviews Disease Primers*, 7(1):3, 2021.
- [12] Carson Stringer, Tim Wang, Michalis Michaelos, et al. Cellpose: a generalist algorithm for cellular segmentation. *Nature Methods*, 2021.
- [13] Vincent A. Traag, Ludo Waltman, and Nees Jan van Eck. From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 9(1):5233, mar 2019.

- [14] Renaud Lambiotte Vincent D. Blondel, Jean-Loup Guillaume and Etienne Lefebvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics*, jul 2008.
- [15] Y. Zhang, S. Vaccarella, E. Morgan, et al. Global variations in lung cancer incidence by histological subtype in 2020: a population-based study. *The Lancet Oncology*, 24:1206–1218, 2023.